

# Semi-Supervised Learning을 사용한 눈 질환 진단 프로그램

노윤지	유다현	조민지	최세민
인공지능응용학과	인공지능응용학과	인공지능응용학과	인공지능응용학과
21102357	21102371	21102390	21102392

## 초록

육안으로 관찰할 수 있는 사람의 눈 데이터를 이용해 눈 질환을 진단할 수 있는 인공지능 프로그램을 구축하였다. 질환 여부 또는 병명이 명시된 데이터의 양이 절대적으로 부족하다는 한계를 보완하기 위해 다수의 라벨이 없는 데이터(Unlabeled Data, UD)를 이용하는 준지도학습을 진행하였으며, 해당 기법 사용의 유효성을 관찰하기 위해 기존 라벨이 있는 데이터로 지도학습한 모델과의 성능 차이를 분석했다.

## 1. 서론

눈(eyes)은 여러 단계의 구조를 통해 시각 정보를 뇌에 전달하는 시각기관이며, 사람이 살아가면서 얻는 정보의 80% 이상이 시각을 통해서 얻어진다.[1] 그러나 신체 중 노화가 가장 빨리 찾아오는 기관인데, 기술이 발전함에 따라 다양한 종류의 전자기기가 등장하였고, 장시간 전자기기 사용으로 안압이 증가하면서 백내장, 녹내장과 같은 안구질환 환자가 크게 증가하였다. 이 두 질환은 시신경 손상과 수정체의 손상으로 인해 발병하며 의료 기기의 보조 없이 육안으로는 둘 사이의 차이를 구별하는 데에 어려움이 있다. 통상적으로 질환 의심자의 접근성을 고려해 의사가 직접 환자의 눈을 살펴봄으로써 눈 질환을

진단하나 이 경우 정밀 기기의 진단에 비해 오진의 가능성이 높다. 이에 따라 이른 시기에 올바른 치료를 받지 못하게 될 최악의 경우 실명위기에 처할 위험 또한 증가하게 된다.

따라서, 이러한 눈 질환의 진단을 위해 일정 수준의 정확도와 높은 접근성이 보장된 수단이 필요하다. 이와 관련하여 주파수 도메인 특성과 인공지능 신경망을 이용하여 눈 질환을 분류하거나[2], 본 연구의 목적과 유사한 준지도학습 기법을 기반으로 눈 질환 이미지를 분류하는 등의 연구가 활발히 진행되고 있다.[3]

본 연구에서는 Kaggle 에서 얻은 눈 질환 labeled 이미지 데이터와 구글이미지 및 크롤링으로 수집한 unlabeled 눈 질환 이미지 데이터를 활용하여 준지도학습 (Semi-Supervised Learning, SSL) 기법을 기반으로 눈 질환 여부 및 해당 질환의 병명의 정확한 분류와 진단 정확도를 측정하였다. 더불어, 진단 정확도를 개선시키고자 준지도학습(SSL) 기반의 Pseudo Labeling(PL)과 Noisy Student (NS) 방법을 사용하여 기존의 지도학습(Supervised Learning, SL)기반의 모델의 정확도 차이를 비교 및 분석하였다.

## 2. 본론

### 2.1 연구 방법론 및 알고리즘

#### 2.1.1 Pseudo Labeling (PL) [4]

$$\text{Loss per Batch} = \text{Labeled Loss} + \text{Weight} * \text{Unlabeled Loss}$$

##### 〈식 1〉 Pseudo Labelling 손실함수

기존의 정답 라벨이 있는 데이터를 학습시킨 Teacher model 에 라벨이 없는 데이터를 학습시켜 확률을 도출하고 이에 기반해 라벨을 부여하는 기법이다. 이 기법은 분류모델의 결정경계(Decision Boundary) 주변에서 데이터의 밀도를 낮출 수 있으며, Unlabeled data 에 대한 엔트로피 (Entropy)를 최소화함으로써 클래스 간 low density separation 을 추구하는 엔트로피 정규화(Entropy Regularization)와 유사한 효과를 유도한다.

#### 2.1.2 Noisy Student (NS) [5]

Pseudo-labeling 된 데이터와 기존에 라벨을 가지고 있던 라벨을 이용하여 Teacher 모델을 학습하고, teacher 모델이 Unlabeled data(UD)를 라벨링하여 teacher 모델보다 같거나 큰 사이즈의 Student 모델을 가지고 labeled data(LD)와 UD 를 학습시킨 기법이다. 추가로, Self-Training 기법[5]에 기초한 것으로 Noisy student 기법 또한 위와 같은 과정을 여러 번 반복해서 성능을 개선시킨다. 즉, Student 모델에 드롭아웃(Dropout), 확률적 깊이 (Stochastic depth), 데이터 증강(Data Augmentation) 등의 노이즈를 추가하여 학습시킴으로써 student 모델은 강력한 앙상블 모델과 같은 장점을 가지게 되며, 이를 통해 성능 개선을

기대할 수 있다.

### 2.2 연구방법

#### 2.2.1 학습 데이터 수집

준지도학습(SSL)을 기반으로 눈 질환 진단 모델을 만들고자 Kaggle에 올라와 있는 Eye disease dataset(ED)[6]을 LD로 활용하였다. ED는 안구돌출(Exophthalmos), 녹내장(Glaucoma), 백내장(Cataracts), 사시(Strabismus), 포도막염(Uveitis) 등으로 총 5개의 클래스로 구성되어 있다.

더불어, 크롤링 과정 중 결막염(conjunctivitis)과 질병여부 판단을 위한 정상(normal) 데이터 또한 추가하였다. 구글과 네이버에서 키워드 16개를 사용하여 크롤링해 얻은 데이터를 UD로 활용하였다. (표1)

Search Keyword
Cataract, Conjunctivitis, Exophthalmos, Eye, Glaucoma, Squint, Strabismus, Uveitis, 결막염, 녹내장, 눈, 눈병, 백내장, 사시, 안구돌출, 포도막염

〈표 1〉 이미지 수집을 위한 검색 키워드

#### 2.2.2 데이터 전처리

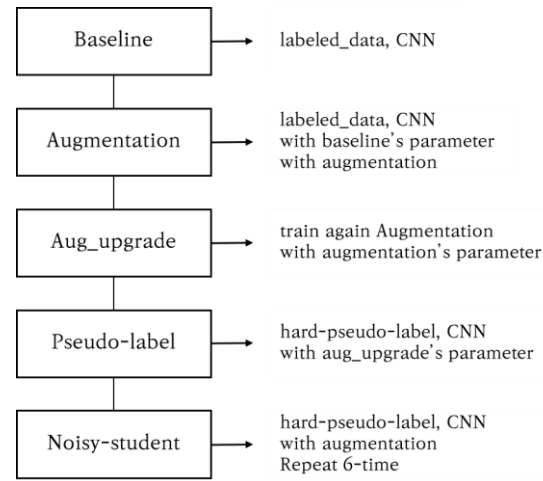
크롤링한 데이터 중 부적절한 이미지를 제외한 후 한쪽 눈만 존재하는 사진을 생성하는 작업을 수행하였다. Kaggle data 에 따르면 사시를 분류 class 에 포함해야 하나 사시는 두 눈의 정렬을 통해 진단됨으로 단일 안구의 증상을 통해 진단되는 다른 질환과의 차이점을 고려하여 사시데이터를 분류 class 에서 제외하였고, 이를 크롭하여 정상 눈 데이터로 사용하였다. 이와 함께 OpenCV[7]를 활용하여 눈 부분만 저장 후 잘못된 크롭 이미지를 직접 제거하여 총 3728 개의 한쪽 눈 데이터를 얻을 수 있었다.

ED 도 같은 과정을 거쳐 클래스당 약 40 여개의 데이터를 얻었다. ED 에 존재하지 않는 결막염과 정상 눈 사진은 검색을 통해 정확하게 판단된 사진만을 모아 30 개 내외의 labeled data 를 각각 생성하였다. 따라서, 본 연구는 총 5 개의 눈 질환 과 정상(normal) 클래스를 분류하고 모델의 성능을 향상시키는 것을 주목적으로 하였다.

ED(labeled data)		Unlabeled_data
Class	N	N
Cataracts	33	3728
Conjunctivitis	25	
Exophthalmos	48	
Glaucoma	24	
Uveitis	42	
Normal	41	
Total	213	3728

〈표 2〉 프로젝트 데이터 구성

### 2.2.3 모델 구축 및 개선



〈그림 1〉 프로젝트 진행과정

Kaggle 데이터를 이용한 눈 질환 진단 모델을 구현하여 일차적으로 분석하였다. 눈 질환 여부와 상세 병명이 명시된 이미지 데이터가 한정적임에 따라 결과는 제한적으로 도출되었으며, 이러한 결과를 개선하기 위하여 다수의 UD 를 도입하였다. SSL 기반의 모델과

SL 기반의 모델을 비교하여 정확도 개선의 정도와 SSL 기법의 유효성 분석을 위해 RandomCrop 과 같은 이미지의 전체 영역을 확인할 수 없는 데이터 증강 기법은 잘못된 질환으로 분류할 가능성이 높아 제외하였다. 본 연구팀의 시간과 resource 관계상 정확도 개선을 위해 사용 가능한 복잡한 모델 사용 및 다양한 데이터 증강기법을 적용하기 다소 어려워 SL 기반의 baseline 에서 augmentation 모델을 반복 시행하였다.

### 3. 실험 결과

Baseline	Augmentation	Aug. upgrade	Pseudo label	Noisy student
0.4577	0.5538	0.6115	0.3269	0.6500

〈표 3〉 각 알고리즘의 모델 정확도

표 3 처럼 LD 만을 사용하여 학습시킨 처음 baseline 모델에서 데이터 증강 기법을 추가 및 반복 실행한 결과 Baseline, Augmentation, Aug.upgrade 모델의 정확도는 각각 46.54%, 58.08%, 65.00%로 지속적인 성능향상을 보였다. 그러나 위의 세 모델보다 성능을 더욱 개선하고자 UD 를 추가하여, PL 모델 및 NS 모델의 학습을 진행하였다.


그 결과, PL 모델이 NS 모델보다 약 32% 더 낮은 정확도를 보였고, 처음 모델보다 약 13% 더 낮은 정확도를 보여 궁극적으로 성능개선 목적을 위해 사용한 PL 모델은 정확도 향상에 유의미하지 않았다.

iteration	0	1	2	3	4	5	6
Num(Data)	168	768	1368	1968	2568	3168	3768
Accuracy	0.4269	0.4962	0.5538	0.4846	0.6308	0.6500	0.5923

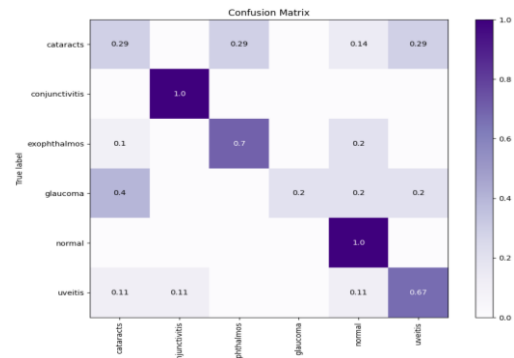
〈표 4〉 Iteration 당 NS 모델의 정확도

표 4 처럼 iteration 당 LD 와 pseudo label 이 부여된 UD 가 합쳐진 데이터의 개수에 따라 NS 모델의 정확도를

측정한 결과 iteration 3 에서 일시적으로 낮은 정확도를 보인 것을 제외하면, 전반적으로 iteration 이 증가할수록 모델의 정확도가 향상되었음을 알 수 있었다. 데이터가 168 개인 경우와 달리, 3168 개인 경우에는 ‘normal(정상)’ 클래스와 ‘conjunctivitis(결막염)’은 완벽하게 분리했음을 다음과 같은 혼동행렬로 나타냈다.



〈그림 2〉 (위)data가 168개일 경우 (아래) 3168개 일 경우




### 3.1 결과 분석

정확한 눈 질환 분류를 위해 눈 전체 이미지만을 가지고 표 3 과 같이 총 5 개의 모델을 학습시켜 궁극적으로 SL 기반 모델의 정확도를 높이기 위해 사용했던 SSL 기반의 모델 중 PL 모델만 정확도 향상에 유의미하지 않았음을 알 수 있었다. 따라서 데이터와 알고리즘 이 두 가지 측면으로 분석하였다.

먼저, 데이터 측면에서 보면 unlabeled data 선정 기준이 모호하여[8] 본 연구팀의 주관이 개입되었고,

데이터 부족으로 충분한 학습이 불가하여 낮은 정확도를 기록하였다고 본다.

알고리즘 측면에서는 불러온 augmentation upgrade 모델의 파라미터가 올바른 학습으로 얻은 파라미터가 아니므로 학습 과정에서 pseudo label 을 잘못 부여하였다고 본다. 논문에 따르면, alpha 에 비례하여 모델의 성능이 좋아진다고 서술하지만[4] 본 연구팀의 결과에서는 파악하기 어려웠다.



〈그림 3〉 Validation accuracy 와 alpha weight 비교

## 4. 결론

본 연구는 준지도학습 알고리즘인 pseudo-label 과 noise-student 를 이용하여 눈 질환을 진단하는 프로그램을 구현하였으며 두 알고리즘 모두 hard pseudo label 을 사용하였다. Pseudo-label 의 정확도(accuracy)는 32.69%, Pseudo-label 의 정확도를 개선하기 위해 사용한 Noisy-student 의 정확도는 65.00%로 관측되었다. 현실에서는 labeled data 가 많지 않기 때문에 많은 unlabeled data 를 활용한 준지도학습을 통하여 약 4%의 성능 향상을 보였다. 추가적으로 구현하지 못한 soft pseudo label 를 부여하 학습을 진행한다면 잘못된 라벨링으로 인하여 발생하는 오류를 줄일 수 있을 것이라 생각한다.

## 참고 문헌

- [1] 고재현, 『눈과 시각』, <<The Science Times>>, 2005, 면 1 쪽
- [2] 신민재, 김대원. (2021). 주파수 도메인 특성과 인공지능 신경망을 이용한 백내장 분류. 대한전자공학회 학술대회, (), 1611-1614.
- [3] Song, W., Cao, Y., Qiao, Z., Wang, Q., & Yang, J. J. (2019, July). An improved semi-supervised learning method on cataract fundus image classification. In *2019 IEEE 43rd Annual Computer Software and Applications Conference (COMPSAC)* (Vol. 2, pp. 362-367). IEEE.
- [4] Lee, D. H. (2013, June). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on challenges in representation learning, ICML* (Vol. 3, No. 2, p. 896).
- [5] Xie, Q., Luong, M. T., Hovy, E., & Le, Q. V. (2020). Self-training with noisy student improves imagenet classification. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 10687-10698).
- [6] Kondwani, "Eye disease dataset", Kaggle, <https://www.kaggle.com/datasets/kondwani/eye-disease-dataset>.
- [7] Asmorekalov, "Open Source Computer Vision Library", <https://github.com/opencv/opencv>
- [8] 정지오, 여일연, & 정희경. (2019). 딥 러닝을 이용한 안면 여드름 분류 모델. *한국정보통신학회논문지*, 23(4), 381-387.